《数据挖掘》实验报告(二)

专	业信息管理与信息系统		
	年级。	2016	
	学 号	_2016214288	
	学生姓名 _	曾德勤	
	指导老师	刘向	

华中师范大学信息管理学院

I 实验目的和意义

数据挖掘设计实验的目的是培养学生具有初步的 python 程序设计、编程、调试的能力。通过实验使学生进一步熟悉并掌握 python 程序的调试运行环境、程序设计过程、程序的基本结构以及程序设计的基本方法。通过实验,使学生将程序设计的理论知识与实践相结合,为学生学习其他计算机编程语言打下基础。

II 实验内容 实验二 关联规则

【实验意义】

关联分析是在一种在大规模数据集中寻找有趣关系的任务。这些关系可以有两种形式: 频繁项目或者关联规则。频繁项集是经常出现在一起的物品的集合,关联规则暗示两种物品 之间可能存在很强的关系。

【实验要求及步骤】

发现毒蘑菇的相似特征,利用这些特征就能避免吃到那些有毒的蘑菇。

- (1) 收集数据:提供文本文件【mushroom.dat】
- (2) 准备数据:解析 tab 键分隔的数据行。
- (3) 训练算法: 使用本章的 apriori()来发现与毒蘑菇有关的特征。

【数据说明】mushroom . dat 的每一行有 23 个数,对应蘑菇的 23 种特征,第一个特征表示有毒或者可食用。如果样本有毒,则值为 2。如果可食用,则值为 1。下一个特征是蘑菇伞的形状,有 6 种可能的值,分别用 3—8 来表示。为了找出毒蘑菇中存在的公共特征,可以运用 Apriori 算法来寻找包含特征值为 2 ,最小支持度为 0.4 的频繁三项集。

【代码参考】

from numpy import *

```
def loadDataSet(fileName): #general function to parse tab -delimited floats
  dataMat = [] #assume last column is target value
  fr = open(fileName)
  for line in fr.readlines():
      curLine = line.split()
      dataMat.append(curLine)
  return dataMat
```

def createC1(dataSet):

```
C1 = \lceil \rceil
    for transaction in dataSet:
        for item in transaction:
            if not [item] in C1:
                C1. append([item])
    C1. sort()
    return map(frozenset, C1) #use frozen set so we
                             #can use it as a key in a dict
def scanD(D, Ck, minSupport):
    ssCnt = \{\}
    numItems = 1.0
    for tid in D:
        for can in Ck:
            if can. issubset(tid):
                if not can in ssCnt: ssCnt[can]=1
                else: ssCnt[can] += 1
        numItems += 1
    retList = []
    supportData = {}
    for key in ssCnt:
        support = ssCnt[key]/numItems
        if support >= minSupport:
            retList. insert (0, key)
        supportData[key] = support
    return retList, supportData
def aprioriGen(Lk, k): #creates Ck
    retList = []
    lenLk = len(Lk)
    for i in range(lenLk):
        for j in range(i+1, lenLk):
            L1 = list(Lk[i])[:k-2]; L2 = list(Lk[j])[:k-2]
            L1. sort(); L2. sort()
            if L1==L2: #if first k-2 elements are equal
                retList.append(Lk[i] | Lk[j]) #set union
    return retList
def apriori(dataSet, minSupport):
    C1 = createC1(dataSet)
    D = map(set, dataSet)
    L1, supportData = scanD(D, C1, minSupport)
    L = [L1]
    k = 2
    while (len(L\lceil k-2\rceil) > 0):
        Ck = aprioriGen(L[k-2], k)
        Lk, supK = scanD(D, Ck, minSupport)#scan DB to get Lk
```

```
supportData.update(supK)
L.append(Lk)
k += 1
return L, supportData
```

【实验报告】

实习时间: 实习地点: 实习机号: (1) 收集数据:提供文本文件【mushroom.dat】 (2) 准备数据:解析 tab 键分隔的数据行。 # coding=UTF-8 具 import apriori1 # 定义最小支持度 体 minSupport = 0.4# 收集数据集 实 dataMap = apriori1.loadDataSet('mushroom.dat') 验 数据打印结果: 内 容

(3) 训练算法: 使用本章的 apriori()来发现与毒蘑菇有关的特征。

```
2 #找出数据集中支持度>=0.4的所有的频繁项集
     3 L, supportData = apriori1.apriori(dataMap, minSupport)
     5 # 从所有的频繁项集中找出频繁3-项集L3
     6 L3 = L[2]
     8 # 遍历频繁3-项集L3, 筛选出包含特征值'2'的频繁3-项集放入结果集中
     9 resultSet = ∏
     0 for freqSet3 in L3:
         if '2' in freqSet3:
            resultSet.append(freqSet3)
     4 print resultSet
     打印结果:
    [frozenset(['39', '2', '86']), frozenset(['39', '2', '85']), frozenset(['39', '2', '34']), frozenset(['90', '39', '2']), frozenset(['2', '59', '34']), frozenset(['2', '86', '85']), frozenset(['90', '2', '85']), frozenset(['39', '2', '59']), frozenset(['90', '2', '86']), frozenset(['2', '28', '85']), frozenset(['2', '86', '34']), frozenset(['59', '2', '86']), frozenset(['34', '2', '85']), frozenset(['2', '59']), frozenset(['90', '2', '34']), frozenset(['2', '59', '85'])] bython task.py 1.82s user 0.11s system 97% cpu 1.973 total
     以上的三项集就是包括'2'(样本有毒特征)的频繁三项集。
     通过本次实验,我了解到了频繁项集产生的过程,并利用收集到的数据集通过
     Apriori 算法找出了包含毒蘑菇特征的频繁三项集。
     利用 Apriori 算法,可以找出所有的频繁-k 项集,然后我们可以根据这些频繁项集
     找到我们想要的公共关系。
     然而仅通过 Apriori 算法找出的频繁项集只是从支持度的角度找出的规则,要使毒
     蘑菇的公共特征更具有可靠性,还需要进行基于支持度的减支产生关联规则:
实
     令最小置信度为 0.7:
     26 # 置信度规则列表
习
     27 bigRuleList = apriori1.generateRules(L, supportData)
      29 # 遍历置信度规则列表,找出毒蘑菇的强关联规则的特征集
小
      30 for item in bigRuleList:
           if (item[0] == frozenset(['2'])):
      31
结
              print item
      32
     33
                         1. vi task.py (vim)
```